



BURSA TEKNİK ÜNİVERSİTESİ

MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

BLM0463 VERİ MADENCİLİĞİNE GİRİŞ

Random Forest ile PhiUSIIL Phishing URL Veri Seti Üzerinde Sınıflandırma

22360859088

KORAY GARİP

Veri seti: <https://archive.ics.uci.edu/dataset/967/phiusiil+phishing+url+dataset>

Github: <https://github.com/korayga/PhishingURLDatasetModels.git>

YouTube: https://youtu.be/yq_4fRWAo_8

İçindekiler

Özet.....	3
1. Giriş	3
2. Veri Seti.....	3
3. Veri Ön İşleme	4
4. Kullanılan Yöntemler.....	4
4.1. Random Forest.....	4
4.2. Karşılaştırma Modelleri	5
5. Deneysel Kurulum.....	5
6. Özellik Setleri.....	5
7. Değerlendirme Metrikleri	6
8. Random Forest Deney Sonuçları.....	6
8.1. Final Test Sonuçları.....	6
8.2. Validation ve Final Test Karşılaştırması.....	7
8.3. Confusion Matrix Analizi.....	8
9. Ek Model Karşılaştırması.....	10
10. Model Dayanıklılığı ve Overfitting Analizi.....	12
11. Akademik Çalışmalarla Karşılaştırma.....	13
12. Ana Model Seçimi	14
13. Sonuç.....	14
Kaynakça.....	14

Özet

Bu projede UCI Machine Learning Repository üzerinde yer alan PhiUSIIL Phishing URL Dataset kullanılarak URL adreslerinin phishing veya legitimate olarak sınıflandırılması amaçlanmıştır. Veri setinde toplam 235.795 örnek ve 56 sütun bulunmaktadır. Hedef değişken label sütunudur; label=0 phishing, label=1 legitimate URL anlamına gelmektedir. Veri setinde eksik değer bulunmamaktadır.

Çalışmada ana sınıflandırma yöntemi olarak Random Forest kullanılmıştır. Model başarısını daha güvenilir değerlendirmek için veri seti %70 eğitim, %15 doğrulama ve %15 final test olacak şekilde ayrılmıştır. Random Forest iki farklı özellik setiyle denenmiştir: tüm sayısal özellikler ve kontrollü özellik seti. Ana model olarak, olası veri sızıntısı veya aşırı güçlü türetilmiş özellik etkisini azaltmak için kontrollü özellik seti seçilmiştir.

Ayrıca Decision Tree, Naive Bayes ve Yapay Sinir Ağları modelleri ile karşılaştırmalar yapılmıştır. Bunun yanında, Random Forest modelinin yüksek başarısının ezberleme kaynaklı olup olmadığını değerlendirmek için sentetik gürültü ekleme ve rastgele veri testleri uygulanmıştır. Elde edilen sonuçlar, modelin yalnızca veriyi ezberlemediğini, gerçek örüntüleri öğrenebildiğini göstermektedir.

1. Giriş

Phishing, saldırganların kullanıcıları sahte web siteleri veya aldatıcı bağlantılar aracılığıyla kandırarak kişisel bilgilerini, giriş bilgilerini veya finansal verilerini ele geçirmeye çalıştığı önemli bir siber güvenlik problemidir. Bu saldırılarda kullanılan URL adresleri çoğu zaman gerçek kurumlara benzetilir, ancak URL yapısı ve web sayfası özellikleri incelendiğinde phishing davranışını yansıtan ipuçları barındırabilir.


Makine öğrenmesi yöntemleri, URL ve web sayfası özelliklerinden öğrenerek phishing tespitinde etkili biçimde kullanılabilir. Bu projenin amacı, PhiUSIIL veri seti üzerinde phishing URL tespiti yapmak, farklı model ve özellik setlerini karşılaştırmak, sonuçları yaygın değerlendirme metrikleriyle sunmak ve literatürdeki çalışmalarla ilişkilendirmektir.

2. Veri Seti

Kullanılan veri seti PhiUSIIL Phishing URL Dataset adlı UCI veri setidir. Veri seti URL yapısı ve web sayfası içeriğinden çıkarılmış özellikler içermektedir. İlk incelemede veri setinde eksik değer olmadığı ve sınıfların çok dengesiz olmadığı görülmüştür.

	Ozellik	Değer
0	Toplam örnek sayısı	235.795
1	Toplam sütun sayısı	56
2	Eksik değer sayısı	0
3	Legitimate URL sayısı	134.850
4	Phishing URL sayısı	100.945
5	Legitimate oranı	%57,1895
6	Phishing oranı	%42,8105

Şekil 1. Veri seti özet tablo



Şekil 2. Veri setindeki phishing ve legitimate sınıf dağılımı

Metinsel sütunlar FILENAME, URL, Domain, TLD ve Title olarak belirlenmiştir. İlk modelleme aşamasında bu sütunlar doğrudan modele verilmemiştir. Böylece ham metinlerin doğrudan ezberlenmesi veya gereksiz kimlik bilgisi etkisi azaltılmıştır.

3. Veri Ön İşleme

Veri ön işleme aşamasında hedef değişken label olarak belirlenmiştir. Phishing sınıfı label=0, legitimate sınıfı label=1 olarak kodlanmıştır. Değerlendirme metriklerinde güvenlik açısından daha kritik olan phishing sınıfı pozitif sınıf gibi ele alınmıştır.

```
veri seti genel bilgileri
boyut: 235,795 satır x 56 sütun
eksik deger sayısı: 0

veri tipleri:
int64    41
float64   10
str       5
Name: count, dtype: int64

metinsel sutunlar: ['FILENAME', 'URL', 'Domain', 'TLD', 'Title']

sayisal sutunlar (51 adet):
['URLLength', 'DomainLength', 'IsDomainIP', 'URLSimilarityIndex', 'CharContinuationRate', 'TLDLegitimateProb', 'URLCharProb', 'TLDLength', 'NoOfSubDomain', 'HasObfuscation']
```

Şekil 3. Veri setindeki sütun dağılımı

4. Kullanılan Yöntemler

4.1. Random Forest

Random Forest, çok sayıda karar ağacının bir araya gelmesiyle oluşan topluluk öğrenmesi yöntemidir. Her ağaç veri ve özellik alt kümeleri üzerinde öğrenir; nihai karar ağaçların çoğunluk oyu ile verilir. Bu yöntem tabular veri setlerinde güçlü performans göstermesi, özellik önem dereceleri sunması ve overfitting riskini tekil karar ağaçlarına göre azaltması nedeniyle tercih edilmiştir.

Parametreler:

- `n_estimators = 100` - 100 karar agaci
- `class_weight = 'balanced'` - sinif dengesizligini otomatik kompanze eder
- `n_jobs = -1` - tum CPU cekirdeklerini kullanir

Şekil 4. Random Forest parametreler

4.2. Karşılaştırma Modelleri

V2 sürümünde Random Forest sonuçlarını daha anlamlı yorumlayabilmek için Decision Tree, Naive Bayes ve Yapay Sinir Ağları (MLP) modelleri de denenmiştir. Bu karşılaştırma, Random Forest modelinin yalnızca tek başına başarılı olup olmadığını değil, aynı veri üzerinde diğer klasik ve sinir ağı tabanlı yöntemlere göre konumunu da göstermektedir.

5. DeneySEL Kurulum

Model seçimini doğrudan final test seti üzerinde yapmamak için veri seti üç parçaya ayrılmıştır. Eğitim seti model öğrenmesi için, doğrulama seti model ve özellik seti karşılaştırması için, final test seti ise seçilen modelin tarafsız değerlendirilmesi için kullanılmıştır.

Veri Bölümü	Oran	Örnek Sayısı	Amaç
Eğitim seti	%70	165.056	Modelin öğrenmesi
Doğrulama seti	%15	35.369	Model varyantlarının karşılaştırılması
Final test seti	%15	35.370	Seçilen modelin tarafsız değerlendirilmesi

6. Özellik Setleri

Çalışmada iki farklı özellik seti kullanılmıştır. Bu yaklaşım, yalnızca en yüksek accuracy değerini raporlamak yerine modelin hangi tür bilgilerle ne kadar başarılı olduğunu analiz etmeyi sağlamıştır.

Özellik Seti	Özellik Sayısı	Açıklama
Tüm sayısal özellikler	50	Metinsel sütunlar çıkarıldıktan sonra kalan tüm sayısal özellikler kullanılmıştır.
Kontrollü özellik seti	44	Aşırı güçlü/türetilmiş olabilecek 6 özellik çıkarılmıştır. Ana model olarak seçilmiştir.

Kontrollü özellik setinde çıkarılan özellikler şunlardır: URLSimilarityIndex, CharContinuationRate, TLDLegitimateProb, URLCharProb, DomainTitleMatchScore ve URLTitleMatchScore. Bu özelliklerin çıkarılması, modelin başarısının yalnızca çok güçlü türetilmiş değişkenlere bağlı olup olmadığını tartışabilmek için yapılmıştır.

7. Değerlendirme Metrikleri

Model performansı accuracy, precision, recall/sensitivity, specificity, F1-score ve ROC-AUC metrikleriyle değerlendirilmiştir. Güvenlik uygulamalarında phishing URL'nin kaçırılması daha kritik olduğundan phishing recall değeri özellikle önemlidir.

Metrik	Açıklama
Accuracy	Toplam doğru tahminlerin tüm tahminlere oranı
Precision	Phishing tahmini yapılan örneklerin gerçekten phishing olma oranı
Recall / Sensitivity	Gerçek phishing örneklerin doğru yakalanma oranı
Specificity	Gerçek legitimate örneklerin doğru legitimate sınıflandırılma oranı
F1-score	Precision ve recall metriklerinin harmonik ortalaması
ROC-AUC	Modelin farklı eşiklerde sınıfları ayırma başarısı


8. Random Forest Deney Sonuçları

8.1. Final Test Sonuçları

özellik seti karşılaştırma tablosu						
Özellik Seti	Özellik Sayısı	Accuracy (%)	Precision (%)	Recall (%)	F1-Score (%)	ROC-AUC
Tüm Sayısal Özellikler	50	99.9972	100.0000	99.9934	99.9967	1.0
Kontrollü Özellik Seti	44	99.9746	99.9736	99.9670	99.9703	1.0

Şekil 5. Model Sonuçları

Final test sonuçlarına göre tüm sayısal özelliklerle eğitilen model en yüksek başarıyı vermiştir. Ancak bu modelde sınıflandırmayı çok kolaylaştırabilecek bazı türetilmiş özellikler bulunduğu için ana model olarak kontrollü özellik seti tercih edilmiştir. Kontrollü model final testte %99,9746 accuracy, %99,9670 phishing recall ve %99,9703 F1-score değerlerine ulaşmıştır.



Şekil 6. Random Forest özellik seti karşılaştırması


8.2. Validation ve Final Test Karşılaştırması

Model	Split	Accuracy	Precision	Recall	Specificity	F1	ROC-AUC
Tüm Sayısal Özellikler	Validation	100.0000	100.0000	100.0000	100.0000	100.0000	100.0000
Tüm Sayısal Özellikler	Final Test	99.9972	100.0000	99.9934	100.0000	99.9967	100.0000
Kontrollü Özellik Seti	Validation	99.9859	99.9868	99.9802	99.9901	99.9835	100.0000
Kontrollü Özellik Seti	Final Test	99.9746	99.9736	99.9670	99.9802	99.9703	100.0000


Validation ve final test sonuçlarının birbirine yakın olması, model performansının yalnızca tek bir bölmeye bağlı olmadığını göstermektedir. Özellikle kontrollü özellik setinde validation accuracy %99,9859, final test accuracy ise %99,9746 olarak gerçekleşmiştir.

8.3. Confusion Matrix Analizi


Confusion matrix değerleri güvenlik açısından önemlidir. En kritik hata tipi FN değeridir; çünkü bu durumda gerçek phishing URL legitimate olarak sınıflandırılır. Ana model olan kontrollü özellik seti final testte yalnızca 5 phishing URL'yi kaçırmış ve 4 legitimate URL için yanlış alarm üretmiştir.



Şekil 7. Ana model final test confusion matrix grafiği



Şekil 8. Final test ROC eğrileri karşılaştırması




Şekil 9. Ana model kontrollü özellik seti için feature importance grafiği

9. Ek Model Karşılaştırması

Projeyi yalnızca Random Forest sonucu ile sınırlamamak için aynı problem üzerinde Decision Tree, Naive Bayes ve Yapay Sinir Ağları (MLP) modelleri de denenmiştir. Bu bölümdeki sonuçlar, Random Forest algoritmasının diğer modellere kıyasla genel olarak en dengeli ve en yüksek performansı verdiğini göstermektedir.


... model karsilastirma tablosu (f1-score siralamasi)					
Model	Accuracy (%)	Precision (%)	Recall (%)	F1-Score (%)	ROC-AUC
Random Forest	99.99	99.99	99.98	99.99	1.0000
Deep MLP (3 Katman)	99.96	99.96	99.95	99.95	1.0000
AdaBoost	99.95	99.94	99.94	99.94	1.0000
Decision Tree	99.88	99.83	99.89	99.86	0.9988
Neural Network (MLP)	99.71	99.39	99.93	99.66	0.9999
K-Nearest Neighbors	99.48	99.63	99.15	99.39	0.9985
Naive Bayes (Bernoulli)	98.44	99.60	96.75	98.15	0.9990
Naive Bayes (Gaussian)	96.37	92.36	99.77	95.92	0.9986

Şekil 10. Model karşılaştırması




Şekil 11. Algoritmalar karşılaştırması

Tum Modellerin Performans Karsilastirmasi



Şekil 12. Algoritmalar karşılaştırması




Şekil 13. Tüm modellerin roc eğrileri karşılaştırması

Karşılaştırma sonuçlarında Random Forest modeli, accuracy, precision, F1-score ve ROC-AUC bakımından en yüksek ve en dengeli sonuçları üretmiştir. Decision Tree modeli de yüksek başarı göstermiştir; ancak Random Forest, çok sayıda karar ağacının ortak kararıyla çalıştığı için tek karar ağacına göre daha kararlı bir modeldir. Naive Bayes (Gaussian ve Bernoulli) modellerinde recall yüksek olmasına rağmen precision ve F1-score değerleri daha düşüktür. MLP ve Deep MLP modelleri Random Forest'a oldukça yakın sonuçlar üretmiş, özellikle Deep MLP neredeyse mükemmel performans göstermiştir. Ancak Random Forest, hem daha açıklanabilir olması hem de feature importance sunabilmesi nedeniyle ana yöntem olarak daha uygun bir seçimdir.

10. Model Dayanıklılığı ve Overfitting Analizi

Random Forest modelinin çok yüksek başarı elde etmesi, ilk bakışta overfitting veya veri ezberleme şüphesi doğurabilir. Bu nedenle V2 sürümünde modele ek stres testleri uygulanmıştır. Orijinal test verisine %10 ve %30 oranlarında Gaussian gürültü eklenmiş, ayrıca özelliklerin min-max aralıklarında tamamen rastgele sentetik veri üretilerek modelin tepkisi ölçülmüştür.



Şekil 14. Sentetik gürültü ve rastgele veri testi sonuçları

Gürültü testlerinde başarı oranının bir anda çökmesi yerine kademeli olarak düşmesi, modelin yalnızca eğitim verisini ezberlemediğini destekleyen önemli bir bulgudur. %10 gürültüde accuracy yaklaşık %98,71 seviyesinde kalmış, %30 gibi ciddi bir bozulmada dahi %94,96 başarı elde edilmiştir. Tamamen rastgele sentetik veride başarı oranının %42,82 seviyesine gerilemesi ise modelin anlamsız girdilerde yapay biçimde yüksek başarı üretmediğini göstermektedir.

Bu sonuçlar overfitting olmadığını destekleyen güçlü bir kanıt olarak değerlendirilebilir; ancak tek başına matematiksel kesinlikte bir ispat olarak görülmemelidir. Daha güçlü genelleme iddiası için farklı veri setleriyle çapraz test yapılması veya zaman bazlı dış test setleri kullanılması önerilir. Bu nedenle raporda bu analiz, modelin dayanıklılığını destekleyen ek deney olarak sunulmuştur.

11. Akademik Çalışmalarla Karşılaştırma

Proje yönergesinde veri seti veya benzer problem üzerinde daha önce yapılmış en az bir akademik çalışma ile karşılaştırma yapılması istenmektedir. Bu nedenle phishing URL tespiti literatürü ve PhiUSIIL veri setinin kullanım amacı dikkate alınarak proje sonuçları literatürdeki yaklaşımlarla karşılaştırılmıştır.

Table 3

Performance of various machine learning algorithms on Phishing URL dataset.

Model	Accuracy	Precision	Recall	F1Score	MCC	Training Time
BernoulliNB	0.98644	0.97879	0.9979	0.98826	0.97247	1
PassiveAggressive	0.98021	0.97072	0.9954	0.98291	0.95983	1
SGDClassifier	0.94294	0.91113	0.9975	0.95236	0.88722	2
MultinomialNB	0.68961	0.65277	0.97669	0.78253	0.39829	1
Perceptron	0.98041	0.97039	0.99612	0.98309	0.96027	1
AdaBoost	0.99981	0.99978	0.99989	0.99983	0.99961	13
LightGBM	0.9999	0.99991	0.99993	0.99992	0.99981	1
XGBClassifier	0.99993	0.99993	0.99994	0.99994	0.99985	12
CatBoost	0.99987	0.99981	0.99996	0.99989	0.99974	35
GradientBoosting	0.99978	0.99974	0.99987	0.99981	0.99955	50
Kneighbors	0.99378	0.9933	0.99583	0.99456	0.98729	43
RandomForest	0.99982	0.9998	0.99989	0.99984	0.99963	21
DecisionTree	0.99866	0.99885	0.99881	0.99883	0.99727	2
LogisticRegression	0.99654	0.99712	0.99683	0.99698	0.99294	2
Bagging	0.99923	0.99967	0.99898	0.99932	0.99842	16
Vote_Hard	0.99874	0.99852	0.99928	0.9989	0.99742	83
Vote_Soft	0.99817	0.99802	0.99878	0.9984	0.99625	75
StackingClassifier	0.99979	0.99978	0.99985	0.99981	0.99957	870

Şekil 15. Makale tablosu

Orijinal çalışmada PhiUSIIL veri seti üzerinde farklı sınıflandırma algoritmalarının performansları raporlanmış; özellikle ağaç tabanlı topluluk yöntemleri (Random Forest, XGBoost, LightGBM vb.) yüksek doğruluk, F1 ve ROC-AUC değerleri göstermektedir. Bizim deneylerimizde de seçilen Random Forest modeli —kontrollü özellik seti kullanılarak ve %70/%15/%15 eğitim-doğrulama-test ayrımı ile— benzer şekilde yüksek doğruluk, F1 ve ROC-AUC değerleri elde etmiş olup, orijinal çalışmanın bulgularını desteklemektedir. Bununla birlikte veri ön işleme, özellik seçimi ve değerlendirme protokollerindeki farklılıklar nedeniyle doğrudan nicel eşleştirme sınırlıdır; yine de elde edilen uyumluluk, ağaç tabanlı topluluk yöntemlerinin bu görev için hem etkili hem de genelleştirilebilir olduğunu ortaya koymaktadır.

Bu projenin güçlü yönü, yalnızca yüksek accuracy raporlamak yerine modelin başarısını farklı özellik setleri, farklı algoritmalar ve sentetik stres testleriyle tartışmasıdır. Böylece yüksek başarının veri setindeki yapısal ayrıştırıcılıktan kaynaklandığı daha ikna edici biçimde gösterilmiştir.

12. Ana Model Seçimi

Deney sonuçları değerlendirildiğinde tüm sayısal özellikler modeli en yüksek sonucu vermiştir. Ancak bu modelde sınıflandırmayı çok kolaylaştırabilecek bazı türetilmiş özellikler yer almaktadır. Bu nedenle raporda ana model olarak Random Forest - Kontrollü Özellik Seti seçilmiştir.

- Kontrollü model, güçlü/türetilmiş 6 özellik çıkarılmış olmasına rağmen çok yüksek başarı sağlamıştır.
- Final testte yalnızca 5 phishing URL kaçırılmış ve 4 legitimate URL için yanlış alarm üretilmiştir.
- Validation ve final test sonuçları birbirine yakındır.
- Random Forest, diğer algoritmalarla karşılaştırıldığında en dengeli sonuçları vermiştir.
- Feature importance ve confusion matrix analizleriyle açıklanabilir bir rapor yapısı sunmaktadır.

Metrik	Ana Model Final Test Sonucu
Accuracy	%99,9746
Phishing Precision	%99,9736
Phishing Recall / Sensitivity	%99,9670
Phishing Specificity	%99,9802
Phishing F1-score	%99,9703
ROC-AUC	%100,0000

13. Sonuç

Bu projede PhiUSIIL Phishing URL veri seti üzerinde phishing URL sınıflandırması yapılmıştır. Ana yöntem olarak Random Forest kullanılmış, model iki farklı özellik setiyle değerlendirilmiştir. Kontrollü özellik seti, yüksek başarı ve daha savunulabilir deney tasarımı nedeniyle ana model olarak seçilmiştir.

Ek olarak Decision Tree, Naive Bayes ve MLP modelleri ile yapılan karşılaştırma Random Forest'ın genel olarak en dengeli performansı verdiğini göstermiştir. Sentetik gürültü testleri de model başarısının yalnızca ezberlemeye dayanmadığını desteklemiştir. %10 ve %30 gürültü altında performansın kademeli düşmesi, tamamen rastgele veride başarının şans seviyesine yaklaşması modelin anlamlı yapısal örüntüler öğrendiğini göstermektedir.

Sonuç olarak Random Forest algoritması, PhiUSIIL veri setinde phishing URL tespiti için çok başarılı bir yöntem olarak değerlendirilmiştir. Ancak gerçek dünyada daha güçlü genelleme iddiası için farklı veri setleriyle dış test yapılması, zaman bazlı test setleri oluşturulması ve SHAP gibi açıklanabilir yapay zekâ yöntemleriyle özellik etkilerinin daha ayrıntılı analiz edilmesi önerilir.

Kaynakça

1. UCI Machine Learning Repository, PhiUSIIL Phishing URL Dataset, <https://archive.ics.uci.edu/dataset/967/phiusiil+phishing+url+dataset>

2. Tupsamudre, H., Jain, S., Lodha, S. PhishMatch: A Layered Approach for Effective Detection of Phishing URLs. arXiv:2112.02226.
3. Purwanto, R., Pal, A., Blair, A., Jha, S. PhishSim: Aiding Phishing Website Detection with a Feature-Free Tool. arXiv:2207.10801.
4. Maneriker, P. et al. URLTran: Improving Phishing URL Detection Using Transformers. arXiv:2106.05256.
5. Mia, M., Derakhshan, D., Pritom, M. M. A. Can Features for Phishing URL Detection Be Trusted Across Diverse Datasets? A Case Study with Explainable AI. arXiv:2411.09813.
6. Scikit-learn Documentation, RandomForestClassifier, <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>
7. Ahammad, S.H., Kale, S.D., Upadhye, G.D., Pande, S.D., Babu, E.V., Dhumane, A.V., Ba hadur, M.D.K.J., 2022. Phishing URL detection using machine learning methods. Adv. Eng. Softw. 173, 103288. <https://doi.org/10.1016/j.advengsoft.2022.103288>.